Universidad Autónoma de la Ciudad de México

Plantel San Lorenzo Tezonco



Docente: Mtra. Araceli Liliana Reyes Cabello

Integrantes del equipo Las Galácticas:

Zambrano Osorno Sarai

Díaz Dorado Rosa Isela

Avance 01: Problema, datos y plan analítico.

Analítica de Incidentes Viales CDMX (C4/C5).

Descripción del Proyecto

El proyecto de Inteligencia de Negocios tiene como propósito analizar los incidentes viales registrados en la Ciudad de México durante el período 2017-2019. El análisis se enfocará en identificar patrones de concentración según alcaldía, día de la semana, franja horaria y tipo de incidente. Los resultados permitirán generar información que pueda apoyar la planeación y asignación preventiva de recursos de emergencia. El proyecto utilizará herramientas de análisis y visualización de datos para transformar los registros disponibles en información útil para la toma de decisiones.

Recursos y Enlaces del Proyecto

- **Fuente de Datos:** Mexico Road Accidents during 2017-2019 (Kaggle)
- **Fuente Inegi:** inegi/accidentes
- **Fuente C5:** datos/C5
- **Repositorio en GitHub:** Repositorio Galácticas

Problema Organizacional

El proyecto plantea un escenario de análisis relacionado con la atención y prevención de incidentes viales en la Ciudad de México. Para este propósito se utilizarán registros de incidentes viales correspondientes al período 2017-2019, con información que permite estudiar su distribución temporal y espacial.

El análisis se plantea como un ejercicio académico de Inteligencia de Negocios. Por lo tanto, no se afirma que las autoridades utilicen actualmente esta herramienta ni que los datos del proyecto correspondan directamente a un sistema operativo vigente de la SSC, SEMOVI o C5.

Situación problemática

Los registros de incidentes viales recopilados por instituciones como el C5 y el INEGI contienen datos valiosos para identificar patrones de riesgo según la ubicación, el día y la hora en que ocurren las emergencias. Sin embargo, debido a que esta información se encuentra separada y en volúmenes masivos, resulta difícil analizar las variables de forma conjunta para saber con certeza qué zonas y horarios presentan la mayor cantidad de percances. Por ello, este proyecto utiliza herramientas de Inteligencia de Negocios (BI) para reunir, organizar y visualizar geográficamente estos registros históricos, transformándolos en evidencia clara que apoye la planeación y la asignación preventiva de recursos de emergencia.

Actores involucrados

- **¿Quiénes requieren la información?**
  Analistas de datos y personal operativo encargados de procesar, validar y estructurar los registros de incidentes.
- **¿Quiénes utilizan los resultados para tomar decisiones?**
  Tomadores de decisiones de mandos medios y altos, responsables de la planeación y la asignación preventiva de recursos de emergencia.

Decisión a Apoyar

La decisión que se busca apoyar consiste en identificar las zonas, días y horarios que presentan mayor concentración de incidentes viales, con el propósito de proporcionar evidencia que pueda utilizarse para priorizar o ajustar de manera preventiva la asignación de recursos de emergencia.

Alcance

El análisis se limitará a los registros disponibles del conjunto de datos seleccionado, correspondientes al período 2017-2019 y relacionados con incidentes viales en las 16 alcaldías de la Ciudad de México.

El proyecto se enfocará en analizar la distribución de los incidentes de acuerdo con su ubicación, temporalidad y tipo. No se pretende determinar las causas de los accidentes ni estimar el costo económico de los daños, debido a que estos aspectos quedan fuera del alcance de la información considerada para este avance.

Pregunta de Negocio

¿En qué alcaldías, días de la semana y franjas horarias se concentra la mayor cantidad de incidentes viales y cuáles son los tipos de incidentes más frecuentes para priorizar la asignación preventiva de recursos de emergencia?

Justificación del Uso de Inteligencia de Negocios (BI)

- **Procesamiento eficiente:** Permite consolidar y estructurar miles de folios de llamadas de emergencia en un modelo analítico fácil de consultar.
- **Visualización dinámica:** Facilita la identificación rápida de patrones de siniestralidad mediante tableros e indicadores clave en lugar de reportes estáticos.
- **Trazabilidad de la información:** Garantiza que el análisis de datos sea auditable, reproducible y sin manipulaciones manuales directas en los registros.
- **Soporte a decisiones:** Permite sustituir la asignación empírica de patrullas y ambulancias por una planificación fundamentada en evidencia histórica.

Dataset de Kaggle + fuente alternativa.

Criterio	**Dataset de Kaggle**	**Fuente alternativa: Datos Abiertos CDMX / C5**

Relación con la pregunta	Alta. Contiene folio, fecha, hora, día de la semana, alcaldía y tipo de incidente, variables directamente relacionadas con la pregunta.	Alta. El conjunto oficial del C5 contiene folio, fecha y hora de creación, día de la semana, motivo/tipo de incidente, alcaldía, ubicación y otros campos relevantes.
Formato y tamaño	CSV, adecuado para cargar y procesar en herramientas de BI.	Dispone de CSV y XLSX. Las bases históricas están separadas por periodos para facilitar su manipulación.
Licencia y procedencia	Dataset publicado en Kaggle por Eduardo Romero, basado en información del C4-C5 CDMX. La plataforma Kaggle funciona como medio de distribución.	Procedencia institucional directa: C5 del Gobierno de la Ciudad de México. El portal indica licencia Creative Commons Attribution 4.0.
Metadatos y diccionario	Tiene información descriptiva proporcionada por quien publicó el dataset, pero dependemos de la documentación disponible en Kaggle.	Ventaja: el portal oficial proporciona un diccionario de datos descargable en XLSX.
Cobertura y granularidad	Corresponde a incidentes viales del periodo indicado en el dataset y trabaja a nivel de registro/folio.	El conjunto oficial registra incidentes viales del C5 desde 2014 y ofrece recursos históricos por periodos, incluyendo 2019–2021.
Limitaciones y riesgos	Al ser una copia/distribución de terceros, debemos comprobar que las columnas, registros y transformaciones correspondan con la fuente institucional original.	Puede presentar actualizaciones históricas y las bases están separadas por periodos; además, los datos representan reportes registrados por C5, por lo que no necesariamente equivalen a todos los accidentes viales ocurridos.
Decisión sobre la fuente	Aceptar con cautela. Es adecuada para desarrollar el análisis, pero debe contrastarse con la fuente institucional.	Aceptar. Es la fuente institucional que permite validar procedencia, variables y metadatos.

Inventario de archivos o tablas

Archivo o tabla	**Filas y columnas**	**Formato**	**Unidad de observación**	**Cobertura**	**Función posible**

Mexico Road Accidents during 2017-2019	Pendiente de verificar con el archivo original	CSV	Un registro de incidente vial asociado a un folio	2017–2019, según la descripción del dataset	Analizar concentración de incidentes por alcaldía, día, horario y tipo

Inventario de columnas

Columna	**Tipo aparente**	**Significado / unidad**	**Ejemplo**	**Duda o problema visible**
folio	Texto	Identificador del incidente	C5/190501/07180	Verificar unicidad y duplicados
fecha_creacion	Fecha almacenada como texto	Fecha de creación del reporte	01/05/19	Verificar formato y cobertura
hora_creacion	Hora almacenada como texto	Hora de creación	21:25:47	Puede convertirse a hora
dia_semana	Categórico	Día de la semana	Miércoles	Verificar categorías consistentes
codigo_cierre	Texto	Código/descripción del cierre	(A) La unidad	Campo de texto largo; revisar categorías
fecha_cierre	Fecha almacenada como texto	Fecha de cierre	01/05/19	Verificar formato
año_cierre	Numérico	Año del cierre	2019	Comparar con fecha de cierre
mes_cierre	Categórico	Mes del cierre	Mayo	Comparar con fecha
hora_cierre	Hora almacenada como texto	Hora de cierre	22:25:45	Verificar formato

delegacion_inicio	Categórico	Alcaldía donde inicia el reporte	MIGUEL HIDALGO	Revisar nombres/categorías
incidente_c4	Categórico	Tipo de incidente	accidente-choque sin lesionados	Revisar categorías
latitud	Numérico/texto	Coordenada geográfica	1.939.984.571*	Formato sospechoso; validar
longitud	Numérico/texto	Coordenada geográfica	-9.918.160.571*	Formato sospechoso; validar
clas_con_f_alarma	Categórico	Clasificación del incidente	EMERGENCIA	Revisar categorías
tipo_entrada	Categórico	Medio de entrada del reporte	LLAMADA DEL 911	Revisar categorías
delegacion_cierre	Categórico	Alcaldía asociada al cierre	MIGUEL HIDALGO	Diferenciarla de delegacion_inicio
geopoint	Geográfico/texto	Coordenadas del incidente	19.39984571,-99.18160571	Parece más consistente que latitud/longitud; validar
mes	Numérico	Número de mes	5	Verificar correspondencia con fecha

Señales visibles y dudas iniciales

En la primera revisión se identificaron algunos aspectos que deberán verificarse antes de realizar la limpieza de los datos:

- Posibles valores faltantes en algunas columnas.
- Los campos de fecha y hora aparecen inicialmente como texto.
- Se debe verificar si existen folios duplicados.
- Algunas categorías y códigos requieren revisión para confirmar su consistencia.
- Se detectó una posible diferencia de formato entre las columnas de coordenadas y `geopoint`.
- Se deberá confirmar la cobertura temporal y el significado de cada variable mediante el diccionario de datos.

Estos aspectos se documentan como hallazgos iniciales y serán revisados durante el perfilamiento y la etapa de limpieza.

Mapa preliminar de análisis

Aquí basta con indicar:

Evento: incidente vial registrado por folio.
Dimensiones: alcaldía, día de la semana, franja horaria y tipo de incidente.
Medida principal: conteo de incidentes.
KPI inicial: total de incidentes viales.

Preguntas secundarias:

1. ¿Qué alcaldías concentran más incidentes?
2. ¿Qué días presentan más reportes?
3. ¿Qué franjas horarias concentran más incidentes?
4. ¿Qué tipos de incidentes son más frecuentes?
5. ¿Qué combinación de alcaldía, día y horario presenta mayor concentración?

Arquitectura de BI

Datos crudos → Python → ETL → PostgreSQL → SQL analítico → Power BI → Interpretación

- **Python:** revisión y preparación de los datos.
- **ETL:** transformación y carga de información.
- **PostgreSQL:** almacenamiento estructurado.
- **SQL:** consultas y métricas.
- **Power BI:** visualización mediante indicadores y gráficas.
- **Interpretación:** análisis de resultados para apoyar la planeación preventiva.

Riesgos y dudas

Riesgo o duda	**Efecto posible**	**Atención**
Valores faltantes	Menos registros utilizables	Revisar en Python

Folios duplicados	Alteración de conteos	Verificar unicidad
Coordenadas con distinto formato	Problemas geográficos	Validar formatos
Cobertura limitada	No representa otros periodos	Considerarlo al interpretar
Datos de C5	No incluye necesariamente todos los accidentes	Aclarar alcance
Kaggle como distribución		

Conclusión

El proyecto es viable porque los datos contienen las variables necesarias para analizar los incidentes por alcaldía, día, horario y tipo. Sin embargo, antes de interpretar los resultados se deberán revisar valores faltantes, duplicados, formatos y posibles inconsistencias.

Como siguiente paso se realizará el perfilamiento de los datos en Python y posteriormente la limpieza, transformación y carga a PostgreSQL para continuar con el análisis en SQL y Power BI.