Universidad Autónoma de la Ciudad de México

Plantel San Lorenzo Tezonco



Docente:

Mtra. Araceli Liliana Reyes Cabello

Integrantes del equipo Las Galácticas:

Zambrano Osorno Sarai

Díaz Dorado Rosa Isela

Avance 02: lectura, perfilamiento y preparación de datos con Python.

Analítica de Incidentes Viales CDMX (C4/C5).

1. Continuidad con el avance 01

Pregunta de Negocio

¿En qué alcaldías, días de la semana y franjas horarias se concentra la mayor cantidad de incidentes viales y cuáles son los tipos de incidentes más frecuentes para priorizar la asignación preventiva de recursos de emergencia?

Actores involucrados

Tomadores de decisiones de mandos medios y altos, responsables de la planeación y la asignación preventiva de recursos de emergencia

Decisión a apoyar

La decisión que se busca apoyar consiste en identificar las zonas, días y horarios con mayor concentración de incidentes viales, como parte de un diagnóstico inicial que permita identificar en qué zonas y momentos se reportan más incidentes viales. Esta información servirá como antecedente para futuros análisis que puedan contribuir a la planeación preventiva y a la asignación de recursos de emergencia.

Ajustes derivados de la retroalimentación

Observación	**Acción realizada**	**Evidencia**
El proyecto sirve como paso previo a la planeación preventiva, no para planearla todavía	Se reformuló la decisión a apoyar	Sección “Decisión a apoyar” de este informe

Fuente de Datos Seleccionada

- **Fuente principal:** *Mexico Road Accidents during 2017-2019*, de Eduardo Romero (Kaggle). Enlace**.** Descargado el 4 de octubre del 2026.
- **Diccionario de datos** de “Incidentes viales reportados al C5” (Datos Abiertos de la CDMX), usado para respaldar las reglas de limpieza y validación. Enlace. Descargado el 4 de octubre del 2026.

Variables Indispensables

La siguiente tabla muestra las variables clave para responder la pregunta de negocio y la función de cada una en el análisis.

Variable	**Función**
folio	Identifica cada incidente

fecha_creacion	Fecha del reporte
hora_creacion	Franja horaria
dia_semana	Día de la semana
delegacion_inicio	Alcaldía
incidente_c4	Tipo de incidente
geopoint, latitud, longitud	Ubicación geográfica

Tabla 1. *Variables clave del proyecto y su función en el análisis.*

2. Lectura reproducible y verificación inicial

Se leyeron los tres archivos CSV (2017, 2018 y 2019) con Pandas, declarando los parámetros de lectura, y se conservaron los archivos originales sin modificaciones. A continuación se presenta el **contrato de lectura** y la verificación de que la estructura obtenida corresponde con la fuente esperada. El código se encuentra en la sección *1. Lectura* del notebook.

Tabla Contrato de lectura

Campo	**Registro**
Fuente	Kaggle, “Mexico Road Accidents during 2017-2019”
Fecha de obtención	04/10/2026
Archivos	incidentes-viales-c5-2017/2018/2019.csv (Drive: BI S&R/Datos/Kaggle)
Formato / función	CSV, pd.read_csv(sep=",", encoding="utf-8")
Resultado	2017: 226,535 × 18 · 2018: 246,577 × 18 · 2019: 207,634 × 18
Comprobaciones	Mismo tipo (DataFrame), mismas 18 columnas y orden en los 3 archivos, coincide con el inventario del avance 1

Advertencias	El archivo 2019 mezcla años de 2 y 4 dígitos (2017 y 2018 usan 4). Pandas convierte ‘NA’ en nulo por defecto: hay 3 celdas con ‘NA’ en delegacion_inicio y 3 en delegacion_cierre (2019).

Tabla 2. *Contrato de lectura de los archivos 2017-2019.*

Muestra de los datos leídos.

```
2017 <class 'pandas.core.frame.DataFrame'>
            folio fecha_creacion hora_creacion dia_semana  \
0  C5/170622/06952     22/06/2017      20:34:45     Jueves
1  C5/170622/05115     22/06/2017      16:41:14     Jueves
2  C5/170622/03715     22/06/2017      13:44:52     Jueves

                                    codigo_cierre fecha_cierre  año_cierre  \
0  (D) El incidente reportado se registró en dos ...   22/06/2017        2017
1  (D) El incidente reportado se registró en dos ...   22/06/2017        2017
2  (N) La unidad de atención a emergencias fue de...   22/06/2017        2017

  mes_cierre hora_cierre    delegacion_inicio  \
0      Junio    20:39:42           MILPA ALTA
1      Junio    16:46:02              TLAHUAC
2      Junio    16:48:07  VENUSTIANO CARRANZA

                     incidente_c4   latitud  longitud clas_con_f_alarma  \
0  accidente-choque sin lesionados  19.20137 -99.00732        EMERGENCIA
1  accidente-choque sin lesionados  19.29659 -99.03443        EMERGENCIA
2  accidente-choque sin lesionados  19.43053 -99.05260        EMERGENCIA

      tipo_entrada    delegacion_cierre                 geopoint  mes
0  LLAMADA DEL 911           MILPA ALTA  19.20137004,-99.00731988    6
1  LLAMADA DEL 911              TLAHUAC  19.29659004,-99.03443004    6
2  LLAMADA DEL 911  VENUSTIANO CARRANZA  19.43053002,-99.05259996    6
```

Figura 1. *Primeros 3 registros de 2017 (head(3)); cada fila es un incidente vial identificado por su folio.*

3. Inspección y perfilamiento

Antes de modificar cualquier valor se construyó un perfil de los datos. El código está en la sección *2. Perfilamiento* del notebook.

Estructura
Se unieron los tres archivos en una tabla de 680,746 filas y 19 columnas (las 18 originales más archivo_origen, que indica el año de cada fila), sin modificar ningún valor. Cada fila es un incidente vial reportado al C5; la clave candidata es folio.

Tipos de datos
14 columnas son texto (entre ellas las de fecha y hora), 3 son enteras y latitud y longitud son decimales.

Valores faltantes
Las columnas con ausencias son delegacion_inicio (59), delegacion_cierre (41), latitud (443), longitud (435) y geopoint (446); en todas el porcentaje es menor a 0.1 %.

Diversidad de valores
Las alcaldías tienen 16 valores distintos, con nombres consistentes, e incidente_c4 tiene 23 tipos.

Duplicados
No se encontraron filas exactamente duplicadas (0) ni folios repetidos (680,746 folios distintos para 680,746 filas), por lo que folio identifica de forma única cada incidente.

Variables numéricas
mes corresponde al mes de cierre (coincide con fecha_cierre en todas las filas) y año_cierre va de 2017 a 2019. En latitud y longitud hay 13 valores extremos, descritos en la tabla de hallazgos.

Tabla de hallazgos iniciales

La siguiente tabla resume las señales detectadas en el perfilamiento, la evidencia que las respalda, su posible efecto en el análisis y lo que falta aclarar. En esta etapa no se corrigió ningún valor.

Señal	**Evidencia**	**Posible efecto**	**Pendiente**
Fechas y horas como texto	4 columnas de fecha/hora almacenadas como texto	No permite ordenar ni agrupar por fecha o franja horaria	Convertir declarando el formato (2019 mezcla años de 2 y 4 dígitos)
Alcaldía faltante	59 nulos en delegacion_inicio: 56 celdas vacías y 3 con 'NA' (solo en 2019). El diccionario documenta 17 valores y se observan 16 alcaldías.	59 incidentes quedarían fuera del conteo por alcaldía.	Aclarar qué significa la ausencia y confirmar si 'NA' es la categoría 17.
Coordenadas faltantes	En total, 446 filas sin coordenadas completas	Limita el análisis geográfico; los conteos no coinciden entre columnas	Aclarar qué significa la ausencia

Prefijo de folio distinto	Último registro con folio GA/... (los demás C5/...)	Ninguno aparente: el prefijo indica qué centro de emergencias recibió el reporte.	Confirmar a qué centro corresponde el prefijo 'GA', que el diccionario no menciona.
Fechas con formato mixto y fuera de su año	2019 mezcla años de 2 y 4 dígitos; 49 filas con fecha del año anterior al de su archivo; rango 07/12/2016 a 30/11/2019	Agrupar por fecha como texto separa días iguales	Declarar ambos formatos al convertir; definir qué hacer con las 49 filas; confirmar la cobertura de diciembre 2019
Categoría escrita de dos formas	incidente_c4: "Detención ciudadana-accidente automovilístico" (3) y "detención..." (77)	Fragmenta el conteo por tipo	Se unificó en la limpieza (Tabla 4)
Falsas alarmas y registros clasificados como delito	clas_con_f_alarma señala 5,248 falsas alarmas y, aparte, 455 delitos. codigo_cierre (F) señala 5,244 falsas alarmas. Las falsas alarmas coinciden en 5,243 filas	Podrían inflar el conteo de incidentes viales	Consultar el diccionario y decidir si se conservan, separan o excluyen
Tipos de incidente poco viales	incidente_c4 incluye sismo-..., cadáver-... y detención ciudadana-...	Podrían no corresponder a incidentes viales típicos	Consultar el diccionario
Coordenadas con valores extremos	3 latitudes (hasta 195.3) y 10 longitudes (hasta -991.8), todas del 31/12/2018, sin la otra coordenada ni geopoint	Puntos fuera del mapa	Revisar su origen en el diccionario; no se corrigen por suposición

Tabla 3. *Hallazgos iniciales*

4. Limpieza y normalización

Se trabajó sobre una copia (**limpio**); la tabla **incidentes** conserva los valores recibidos. El código está en la sección 3 del notebook.

Bitácora de transformaciones

La siguiente tabla registra las transformaciones aplicadas a la copia de trabajo: el problema, la regla que las respalda, las columnas y los registros afectados, y la comprobación realizada. La tabla **incidentes** conserva los valores recibidos.

Campo	**Fechas**	**Horas**	**Texto de incidente_c4**	**Registros sin alcaldía**
Problema	Fechas como texto, con dos formatos	Horas como texto	Categoría escrita de dos formas	Alcaldía de inicio vacía o con “NA”
Regla y fundamento	El diccionario define el tipo fecha; se declaran dd/mm/aaaa y dd/mm/aa	El diccionario define el tipo hora; formato HH:MM:SS	El mismo tipo de incidente estaba escrito con y sin mayúscula inicial (Detención/detención); se unifica porque no cambia el significado.	Es un campo obligatorio para el conteo por alcaldía; sin ella el incidente no se puede ubicar
Columnas	fecha_creacion, fecha_cierre	hora_creacion, hora_cierre	incidente_c4	delegacion_inicio
Operación	pd.to_datetime con ambos formatos	pd.to_datetime y .dt.time	strip y lower	dropna(subset=["delegacion_inicio"])
Registros afectados	680,746	680,746	3 filas cambian de valor	59 eliminados (4 de 2017, 36 de 2018 y 19 de 2019)

Antes → después	Texto → fecha	Texto → hora	23 → 22 tipos	680,746 → 680,687 filas
Comprobación	0 fallos; 680,746 filas conservadas	0 fallos; filas conservadas	“detención...” suma 80 (77 + 3); filas conservadas	0 nulos restantes en delegacion_inicio; se conserva una copia con todas las filas

Tabla 4. *Bitácora de transformaciones aplicadas a la copia de trabajo.*

Casos a revisar (sin corregir)

En la copia de trabajo se agregaron tres columnas que indican con True o False si una fila tiene un posible problema: coordenadas fuera de rango, falsa alarma o fecha de otro año. Solo se marcaron los casos, sin cambiar ni borrar ningún dato. La siguiente tabla resume cuántas filas hay en cada caso.

Caso señalado	Criterio y fundamento	Filas marcadas	Efecto posible	Pendiente
coord_fuera_rango	Latitud o longitud fuera del rango del diccionario (19.094 a 19.632; -99.371 a -98.929)	13	Puntos fuera del mapa	Revisar su origen; no se corrigen por suposición
es_falso_f	Código de cierre (F): el reporte resultó ser falso, según el diccionario	5,203	Inflan el conteo de incidentes	Decidir si se excluyen en cada análisis. 6 filas no coinciden con clas_con_f_alarma
fecha_otro_anio	Año de la fecha de creación distinto al del archivo	49	Ninguno aparente: los archivos se	Confirmar con el diccionario que los archivos se

			separan por año de cierre	separan por año de cierre

Tabla 5. *Casos a revisar señalados en la copia de trabajo.*

Nota: *archivo_origen coincide con año_cierre en todas las filas: los archivos se separan por año de cierre.*

Decisiones sobre otros tratamientos

La siguiente tabla resume lo que se decidió sobre los demás aspectos de limpieza: qué se conserva, qué no aplica y qué queda pendiente.

Aspecto	**Decisión**	**Fundamento**	**Comprobación**
Faltantes	Se conservan sin rellenar excepto delegacion _inicio	El diccionario no define qué significan las ausencias; rellenarlas sería suponer. Se eliminó delegacio_inicio porque sin alcaldía no podemos responder nuestra pregunta de negocio.	El número de valores faltantes en cada columna es el mismo antes y después de la limpieza (ver 'Valores faltantes' en el perfilamiento).
Duplicados	No aplica	No hay filas duplicadas ni folios repetidos	0 duplicados exactos y 0 folios repetidos
Unidades	No aplica	Ninguna columna mezcla unidades de medida	Revisión de las columnas en el perfil
Categorías	Pendiente	El diccionario documenta 17 categorías en incidente_c4 y se observan 22.	Las variantes dudosas se mantienen sin unir

Tabla 6. *Decisiones sobre faltantes, duplicados, unidades y categorías.*

5. Validación e interpretación

En este capítulo se comprueba que los datos preparados cumplen las condiciones necesarias para el análisis, se compara el resultado con el perfil inicial y se indica cuántas filas quedan disponibles según el uso. El código está en la sección 4 del notebook.

Validaciones

La siguiente tabla resume las comprobaciones ejecutadas sobre los datos preparados: para qué se usan, qué condición se esperaba, qué resultado dieron y qué se hará si fallan. Las que no se cumplen se conservan como evidencia.

Validación	**Uso**	**Condición esperada**	**Resultado**	**Acción si falla**
Campos obligatorios	Conteo por alcaldía, día, hora y tipo	Sin vacíos en folio, fecha, hora, día, alcaldía de inicio y tipo	Cumple	Revisar los registros sin dato y decidir si se eliminan o se conservan, documentando la decisión.
Granularidad	Conteo de incidentes	folio único	Cumple (0 repetidos)	Revisar si hay conflicto entre registros
Tipos	Análisis por fecha y franja horaria	Fechas en tipo fecha y horas en tipo hora, sin fallos de conversión	Cumple	Revisar los valores que no se convirtieron
Categorías	Agrupar por día, alcaldía y código de cierre	Valores dentro del catálogo (7 días, 16 alcaldías, 5 códigos)	Cumple	Revisar los valores sin equivalencia

Categorías de incidente_c4	Conteo por tipo de incidente	Valores dentro del catálogo oficial	Pendiente: el diccionario no lista las 17 categorías	Consultar el diccionario antes de unir categorías
Fechas	Periodo de análisis	Fechas dentro del rango del diccionario y cierre no anterior a la creación	Cumple	Revisar las fechas fuera de rango
Coordenadas	Análisis geográfico	Latitud y longitud dentro del rango del diccionario	No cumple: 13 filas	Se conservan señaladas y no se usan en el análisis geográfico hasta aclarar su origen
Efecto de los cambios	Trazabilidad	Mismo número de filas que la tabla original	Cumple: 680,687 filas; solo se excluyeron las 59 de la R4)	Revisar la transformación que cambió las filas

Tabla 7. *Validaciones de los datos preparados.*

Comparación antes y después

La siguiente tabla compara el perfil inicial con la copia preparada. No se excluyó ninguna fila.

Aspecto	**Antes (incidentes)**	**Después (limpio)**	**Efecto**
Filas	680,746	680,687	Se excluyeron 59 filas (R4).

Columnas	19	22	Se agregaron 3 columnas indicadoras
Fechas y horas	Texto	Fecha y hora	Conversión sin fallos
Tipos de incidente_c4	23	22	Se unificó una categoría (mayúscula)
Faltantes en delegacion_inicio	59	0	Se conservaron sin rellenar
Folios repetidos	0	0	Sin cambio

Tabla 8. *Comparación entre los datos originales y la copia preparada.*

Filas disponibles según el uso

La siguiente tabla muestra cuántas filas quedan disponibles según el análisis. Son subconjuntos de la misma tabla; no se eliminó ninguna fila.

Uso	**Criterio**	**Filas**	**Filas que quedan fuera**
Todos los incidentes	Todas las filas	680,687	0
Conteo por alcaldía	Con alcaldía de inicio	680,687	59
Incidentes no falsos	Sin código de cierre (F)	675,484	5,203
Por alcaldía, sin falsas alarmas	Ambos criterios	675,484	5,203

Análisis geográfico	Coordenadas completas y en rango	680,241	446

Tabla 9. *Filas disponibles según el uso.*

6. Conclusión

En el dataset se reúnen 680,746 incidentes viales reportados al C5 entre diciembre de 2016 y noviembre de 2019. Tras eliminar 59 registros sin alcaldía de inicio (R4), la copia preparada queda con 680,687 incidentes. Estos datos permitirán realizar un análisis posterior para identificar cuándo, dónde y qué tipo de incidentes se reportaron con mayor frecuencia.

Sin embargo, los resultados son descriptivos: no explican las causas de los incidentes ni permiten determinar cómo distribuir los recursos de emergencia sin información adicional, como la gravedad de los incidentes o el flujo vehicular.

Por otra parte, los datos faltantes ya estaban presentes en los archivos originales, por lo que el proceso de limpieza y conversión de fechas y horas no generó nuevos valores vacíos.

Finalmente, con estas limitaciones y pendientes identificados, los datos están preparados para la siguiente etapa del proyecto: cargarlos en PostgreSQL, realizar consultas con SQL y visualizar la información en Power BI, considerando variables como alcaldía, día, horario y tipo de incidente.

Límites para el análisis

Al interpretar los resultados, es importante considerar las siguientes limitaciones:

- Alcaldía: 59 incidentes no tenían alcaldía de inicio y se eliminaron de la copia (R4), por lo que no forman parte de ningún conteo.
- Falsas alarmas: 5,203 incidentes fueron identificados como falsas alarmas mediante el código de cierre (F). Se podrían excluir del conteo para no inflar los incidentes viales.
- Ubicación: 446 incidentes no cuentan con coordenadas completas y válidas, por lo que no pueden representarse en un mapa. De estos, 13 presentan valores fuera de rango.
- Periodo: los registros abarcan hasta el 30 de noviembre de 2019, por lo que no incluyen información de diciembre de ese año.

Pendientes por aclarar

Se identificaron tres aspectos que requieren confirmación mediante el diccionario de datos o directamente con la fuente:

- **Tipos de incidente (incidente_c4):** el diccionario registra 17 categorías, mientras que los datos contienen 22. También falta confirmar si los registros de tipo sismo-..., cadáver-... y detención ciudadana-... deben considerarse incidentes viales.
- **Clasificación (clas_con_f_alarma):** el diccionario no explica los valores de esta columna, por lo que es necesario aclarar su significado, especialmente el valor "DELITO".
- **Coordenadas extremas:** se desconoce por qué existen 13 registros con coordenadas fuera de los rangos geográficos válidos.

7. Bitácora del equipo

La siguiente tabla registra las tareas del avance, quién fue la persona responsable, la evidencia que produjo y su estado. Incluye el ajuste derivado de la retroalimentación.

Tarea	Descripción	Responsable principal	Evidencia producida	Estado
Continuidad con el avance 1 y ajuste por la retroalimentación	Se retomó el avance 1 y se hicieron los cambios que indicó la docente en la retroalimentación.	Sarai	Tabla 1 y tabla de retroalimentación	Completo
Lectura y perfilamiento de los datos	Se leyeron los tres archivos (2017, 2018 y 2019), se unieron en una sola tabla y se revisó su estructura, tipos de datos, valores faltantes y duplicados sin modificar nada.	Sarai	Secciones 1 y 2 del notebook; Tablas 2 y 3	Completo

Limpieza, validación y conclusión	Se trabajó sobre una copia de los datos: se convirtieron fechas y horas, se normalizó el texto de incidente_c4 (espacios y mayúsculas), se marcaron casos a revisar y se eliminaron los 59 registros sin alcaldía. Después se validó el resultado y se redactaron las conclusiones.	Rosa Isela	Secciones 3 y 4 del notebook; Tablas 4 a 9	Completo
README y GitHub	Documentar el proyecto en un README y organizar el repositorio en GitHub.	Rosa Isela	Repositorio	Completo
Presentación y demostración	No se llevó a cabo en este avance.	Sarai y Rosa Isela	Presentación en Gamma	Pendiente

Tabla 10. *Bitácora de equipo.*