Universidad Autónoma de la Ciudad de México

Plantel San Lorenzo Tezonco



Docente:

Mtra. Araceli Liliana Reyes Cabello

Integrantes del equipo Las Galácticas:

Zambrano Osorno Sarai

Díaz Dorado Rosa Isela

Avance 03: integración, análisis descriptivo y diseño de un ETL reproducible

---

Analítica de Incidentes Viales CDMX (C4/C5).

1. Continuidad de los avances anteriores

Pregunta de Negocio

¿En qué alcaldías, días de la semana y franjas horarias se concentra la mayor cantidad de incidentes viales y cuáles son los tipos de incidentes más frecuentes para priorizar la asignación preventiva de recursos de emergencia?

Decisión a apoyar

Identificar las alcaldías, días y horarios con mayor concentración de incidentes viales como diagnóstico inicial. Esta información servirá como antecedente para análisis posteriores que contribuyan a la planeación preventiva y a la asignación de recursos de emergencia.

Fuente de Datos Seleccionada

- **Fuente principal:** *Mexico Road Accidents during 2017-2019*, de Eduardo Romero (Kaggle). Enlace**.** Descargado el 4 de octubre de 2026. La fuente está compuesta por tres archivos CSV con la misma estructura de 18 columnas:
    - incidentes-viales-c5-2017.csv: 226,535 registros
    - incidentes-viales-c5-2018.csv: 246,577 registros
    - incidentes-viales-c5-2019.csv: 207,634 registros
- **Diccionario de datos** de “Incidentes viales reportados al C5” (Datos Abiertos de la CDMX), usado para respaldar las reglas de limpieza y validación. Enlace. Descargado el 4 de octubre de 2026.

Variables Indispensables

La siguiente tabla muestra las variables clave para responder la pregunta de negocio y la función de cada una en el análisis.

Tabla 1. Variables clave del proyecto y su función en el análisis

Variable	Función
folio	Identifica cada incidente
fecha_creacion	Fecha del reporte
hora_creacion	Franja horaria
dia_semana	Día de la semana
delegacion_inicio	Alcaldía
incidente_c4	Tipo de incidente
geopoint, latitud, longitud	Ubicación geográfica

Ajustes derivados de la retroalimentación

Tabla 2. Ajustes de retroalimentación

Observación	Acción realizada	Evidencia
La profesora estuvo de acuerdo con aplicar la regla R4, que consiste en eliminar filas con valores vacíos o NA en delegacion_inicio, ya que sin este dato no es posible responder nuestra pregunta de negocio.	Se eliminaron las filas con celdas vacías o NA en la columna delegacion_inicio.	En el Avance 2 se eliminaron 59 registros con la regla R4 (sección 4, Tabla 4). En este avance se conservan en incidentes_pendientes.csv, para que puedan revisarse.
Faltaba describir el trabajo realizado por cada integrante en la bitácora del equipo.	Se agregó la columna Descripción a la bitácora del equipo para explicar brevemente el trabajo realizado en cada actividad.	Ajuste registrado en el informe del Avance 2, sección 7. *Bitácora del equipo*, Tabla 10. *Bitácora de equipo.*

2. Integración y preparación de fuentes

El proyecto usa una sola fuente, dividida en tres lotes anuales con la misma estructura. Por eso la integración consiste en unir esos lotes con concat. No se forzó un merge, porque no hay catálogos ni otras fuentes que cruzar. El código está en las secciones 1, 2 y 7 del notebook.

Tabla 3. Fuentes y lotes integrados

Archivo	Periodo que cubre	Filas	Columnas
incidentes-viales-c5-2017.csv	2017 (incluye 19 registros de dic. 2016)	226,535	18
incidentes-viales-c5-2018.csv	2018 (incluye 14 registros de 2017)	246,577	18

incidentes-viales-c5-2019.csv	ene.–nov. 2019 (incluye 16 registros de 2018)	207,634	18
Total integrado	07/12/2016 – 30/11/2019	680,746	19

Tabla 4. Evidencia de la integración

Aspecto	Evidencia
Tipo de unión	Concatenación vertical (apilado) de los 3 lotes con la función pd.concat; se agrega la columna archivo_origen para saber de qué archivo anual (2017, 2018 o 2019) viene cada fila.
Clave	Hay 0 folios repetidos entre lotes, así que no hay registros duplicados ni sin correspondencia.
Cobertura	Antes de la unión, los 3 lotes suman 680,746 filas (226,535 + 246,577 + 207,634); después de la unión, la tabla incidentes tiene también 680,746 filas. Son iguales, así que no se perdieron ni se duplicaron registros.
Granularidad	Cada fila representa un incidente vial, identificado por su folio. Esto es igual antes y después de unir los archivos, porque solo se apilaron filas y ningún folio se repite. Por eso no hay incidentes contados dos veces.
Variables derivadas	hora: hora del reporte (0 a 23), obtenida de hora_creacion. franja_horaria: agrupa la hora en cuatro bloques: Madrugada 00–05, Mañana 06–11, Tarde 12–17 y Noche 18–23.
Resumen	Con groupby se cuentan los incidentes válidos por alcaldía, día de la semana y franja horaria. Se obtienen 448 filas (16 alcaldías × 7 días × 4 franjas); cada fila indica cuántos incidentes hubo en esa combinación, por ejemplo: Iztapalapa, viernes, noche = 7,528. La suma de todas las filas es

	680,687, igual al total de válidos. Se guarda en data/processed/resumen_alcaldia_dia_franja.csv.

3. Contrato y ejecución del ETL

El proceso se organizó en funciones dentro del notebook, una por etapa, siguiendo la Nota 11. Los archivos crudos solo se leen y nunca se modifican. Cada etapa registra lo que hizo en la bitácora automática.

Tabla 5. Contrato del ETL

Elemento	Especificación
Entrada esperada	3 archivos CSV (uno por año), separados por comas, en utf-8, con 18 columnas en el mismo orden.
Reglas	R1 fechas, R2 horas, R3 texto, R4 alcaldía, más las variables derivadas (hora y franja_horaria).
Salida	incidentes_preparados.csv (válidos, 24 columnas), incidentes_pendientes.csv (excluidos, con su motivo), controles.csv, resumen_alcaldia_dia_franja.csv y bitacora.csv.
Datos incompatibles	Si falta un archivo o sus columnas no son las esperadas, el proceso se detiene y muestra un error. Si un registro no tiene alcaldía, no se borra: se guarda en pendientes y el proceso continúa con los demás.

Tabla 6. Etapas del ETL

Etapa	Función	Qué hace	Resultado
Extracción	extraer()	Lee cada CSV y verifica sus 18 columnas.	226,535 + 246,577 + 207,634 filas

Integración	integrar()	Apila los 3 lotes y agrega archivo_origen.	680,746 filas, 0 folios repetidos
Transformación	transformar()	Aplica R1, R2 y R3, crea hora y franja_horaria, y marca casos a revisar.	680,746 filas, 0 fallos de conversión
Validación	separar() y controlar()	Aplica R4 (válidos y pendientes) y 9 controles del contrato de salida.	680,687 válidos, 59 pendientes, 9 de 9 controles cumplidos
Preparación y salida	guardar() y guardar_bitacora()	Exporta los CSV y los vuelve a leer para comprobar conteos.	Archivos en data/processed/ y bitacora/

Tabla 7. Reglas de transformación

Regla	Qué hace	Justificación	Resultado
R1 Fechas	Convierte fecha_creacion y fecha_cierre a tipo fecha.	Vienen en dos formatos (dd/mm/aaaa y dd/mm/aa).	0 fallos
R2 Horas	Convierte hora_creacion y hora_cierre a tipo hora.	Se necesitan para obtener la franja horaria.	0 fallos
R3 Texto	Pasa incidente_c4 a minúsculas y sin espacios.	“Detención” venía escrita de dos formas.	23 → 22 tipos
R4 Alcaldía	Separa los registros sin delegacion_inicio.	Sin alcaldía no se responde la pregunta de negocio.	59 pendientes

Casos marcados sin corregir: 13 con coordenadas fuera de rango, 5,244 falsas alarmas (código F) y 49 con fecha de otro año. Se conservan para revisarlos en etapas posteriores.

4. Conciliación y validación del proceso

Antes de guardar, se comprobó que los registros válidos cumplan el contrato de salida y se explicó a dónde fue cada registro original. El código está en las secciones 4 y 6 del notebook, y los resultados en data/processed/controles.csv.

Tabla 8. Controles del contrato de salida

Control	Qué revisa	Casos que no cumplen
Obligatorios sin vacíos	folio, fecha, hora, día, alcaldía, tipo de incidente y franja completos	0
Folio único	Que ningún incidente se repita	0
Fechas en tipo fecha	fecha_creacion y fecha_cierre	0
Horas en tipo hora	hora_creacion y hora_cierre	0
Día de la semana en catálogo	Solo lunes a domingo	0
Alcaldía en catálogo	Solo las 16 alcaldías de la CDMX	0
Código de cierre en catálogo	Solo A, D, N, F o I	0
Fecha de creación en rango	Entre dic. 2016 y 2019	0
Hora en rango	Entre 0 y 23	0

Los 9 controles se cumplen.

Tabla 9. Conciliación de registros

Destino	Registros
Registros originales (3 CSV)	680,746
Repetidos retirados	0
Válidos (incidentes_preparados.csv)	680,687
Pendientes (incidentes_pendientes.csv)	59

680,746 = 0 + 680,687 + 59. La conciliación cuadra y ningún folio aparece en válidos y pendientes a la vez.

Para no contar dos veces los mismos casos, solo se suman las tablas finales (válidos y pendientes). Las tablas incidentes y limpio representan los mismos registros en etapas anteriores, por eso no se suman.

Tabla 10. Conciliación por archivo

Archivo	Originales	Válidos	Pendientes	¿Cuadra?
2017	226,535	226,531	4	Sí
2018	246,577	246,541	36	Sí
2019	207,634	207,615	19	Sí

5. Análisis estadístico descriptivo preliminar

Las medidas se calcularon en la sección 8 del notebook sobre los 680,687 incidentes

válidos (datos preparados). Como las variables clave son categóricas (alcaldía, día, franja y tipo de incidente), se usaron frecuencias y porcentajes; para la variación se construyó la serie de incidentes por día, del 01/01/2017 al 30/11/2019, que es el periodo con cobertura completa, contando como cero los días sin incidentes. Se conservaron las falsas alarmas (5,244), los 49 casos con fecha de otro año y los 13 con coordenadas fuera de rango, porque el análisis mide reportes recibidos por el C5.

Tabla 11. M1: frecuencia y porcentaje por alcaldía

Elemento	Especificación
Pregunta analítica	¿Qué alcaldías concentran más incidentes?
Variable	delegacion_inicio
Justificación	Las categorías no admiten promedio; el porcentaje permite comparar el peso de cada alcaldía.
Resultado	Iztapalapa 111,344 (16.4 %), Gustavo A. Madero 69,597 (10.2 %), Cuauhtémoc 67,755 (10.0 %). Milpa Alta 3,572 (0.5 %).
Interpretación	Tres alcaldías reúnen el 36.6 % de los incidentes. Iztapalapa tiene 1.6 veces los de la segunda.

Tabla 12. M2: media, mediana y desviación estándar de incidentes diarios por día de la semana

Elemento	Especificación
Pregunta analítica	¿Qué días de la semana tienen más incidentes?
Variables	Conteo diario por dia_semana
Justificación	La media da el promedio diario. La mediana comprueba que no esté inflada por días extremos. La desviación estándar mide cuánto varía.
Resultado	Viernes: media 746.0, mediana 749.5, desv. 130.7. Sábado: media 714.3. Domingo: media 578.2.
Interpretación	El viernes es el día más cargado (cerca de 29 % más que el domingo) y también el más variable. Media y mediana son parecidas, así que no hay valores extremos que distorsionen.

Tabla 13. M3: frecuencia y porcentaje por franja horaria

Elemento	Especificación
Pregunta analítica	¿En qué franja horaria se concentran los incidentes?
Variable	franja_horaria
Justificación	Son cuatro franjas de seis horas cada una, por lo que son comparables entre sí.
Resultado	Noche 245,506 (36.1 %), Tarde 216,332 (31.8 %), Mañana 141,331 (20.8 %), Madrugada 77,518 (11.4 %).
Interpretación	El 67.9 % de los incidentes ocurre entre las 12:00 y las 23:59.

Tabla 14. M4: tipos de incidente más frecuentes

Elemento	Especificación
Pregunta analítica	¿Cuáles son los tipos de incidente más frecuentes?
Variable	incidente_c4
Justificación	La pregunta de negocio pide los tipos más frecuentes.
Resultado	Choque sin lesionados 52.7 %, choque con lesionados 24.0 %, atropellado 13.3 %, motociclista 6.1 %, volcadura 2.3 %.
Interpretación	Los cinco tipos reúnen el 98.4 %. Uno de cada cuatro incidentes es un choque con lesionados, y los atropellados son más frecuentes que los de motociclistas.

Tabla 15. M5: media, mediana, desviación estándar y percentil 90 de incidentes diarios por alcaldía

Elemento	Especificación
Pregunta analítica	¿Cuántos incidentes diarios maneja cada alcaldía y qué tan cargados son sus días más críticos?
Variables	Conteo diario por delegacion_inicio
Justificación	El percentil 90 muestra la carga en los días altos, útil para dimensionar recursos y no solo el día típico.
Resultado	Iztapalapa: media 104.6, mediana 102.0, desv. 29.0, p90 142. Milpa Alta: media 3.4, p90 7.

Interpretación	En 1 de cada 10 días Iztapalapa recibe unos 142 incidentes o más. Iztapalapa promedia cerca de 30 veces lo de Milpa Alta.

Interpretación general

Los incidentes se concentran en Iztapalapa (16.4 %), los viernes (746 al día en promedio) y sábados (714), y en la noche, de 18:00 a 23:59 (36.1 %). El tipo más frecuente es el choque sin lesionados (52.7 %).

6. Bitácora automática y trazabilidad

La bitácora del ETL se genera con la función anotar(), adaptada de la Nota 11 y definida desde el inicio, en la sección 0. Configuración del notebook. Esta función registra cada operación del proceso, y al final guardar_bitacora() la exporta automáticamente a bitacora/bitacora.csv.

Tabla 16. Campos de la bitácora automática

Campo	Qué registra
fecha	Fecha y hora de la operación (hora de México)
archivo	Archivo o tabla que se trabajó
paso	Etapa del proceso que se ejecutó (por ejemplo, extraer, integrar o R1_fechas).
filas_antes	Filas antes de la operación
filas_despues	Filas después de la operación
detalle	Qué cambió
responsable*	Quién ejecutó el proceso

regla*	Regla o criterio aplicado
resultado*	Correcto o Con observaciones
observaciones*	Cifras o casos relevantes

En la Tabla 17 se muestran los pasos que la bitácora registró automáticamente: cuántas filas había antes y después de cada operación y su resultado.

Tabla 17. Pasos registrados en bitacora.csv

Paso	Antes	Después	Resultado	Observación
extraer (2017)	226,535	226,535	Correcto	Archivo crudo sin cambios
extraer (2018)	246,577	246,577	Correcto	Archivo crudo sin cambios
extraer (2019)	207,634	207,634	Correcto	Archivo crudo sin cambios
integrar	680,746	680,746	Correcto	0 folios repetidos
R1_fechas	680,746	680,746	Correcto	0 fallos
R2_horas	680,746	680,746	Correcto	0 fallos
R3_texto	680,746	680,746	Correcto	23 → 22 tipos

derivar_franja	680,746	680,746	Correcto	0 sin franja
marcar_casos	680,746	680,746	Con observaciones	13 coordenadas, 5,244 falsas alarmas, 49 de otro año
R4_separar	680,746	680,687	Con observaciones	59 pendientes
controles	680,687	680,687	Correcto	9 de 9 cumplidos
guardar	680,746	680,746	Correcto	Archivos CSV en la carpeta data/processed: preparados 680,687 y pendientes 59
conciliar	680,746	680,746	Correcto	Originales (680,746) = repetidos (0) + válidos (680,687) + pendientes (59); ningún folio repetido entre válidos y pendientes
resumir	680,687	448	Correcto	448 combinaciones (16 alcaldías × 7 días × 4 franjas); suma de incidentes = 680,687 válidos
estadistica	680,687	680,687	Correcto	5 medidas (M1 a M5); resultados en la sección 8 del notebook
reproducibilidad	680,687	680,687	Correcto	Misma huella de los válidos en las 2 ejecuciones

7. Reproducibilidad, limitaciones y cierre

El proceso se ejecutó dos veces desde los tres CSV crudos, sin correcciones manuales, y las dos ejecuciones produjeron exactamente la misma tabla preparada. La comprobación está en la sección 9 del notebook.

Tabla 18. Comprobación de reproducibilidad

Elemento	Especificación
Procedimiento	Se repitió extraer, integrar, transformar y separar desde los 3 CSV crudos, que no se modifican.
Comparación	Se resumió cada tabla en una huella (código MD5 del contenido) y se compararon las de la primera y la segunda ejecución.
Resultado	Válidos: 680,687 en ambas ejecuciones. Pendientes: 59 en ambas. Huella de los válidos: 99fabc4ea38f98671fa9a4e7e637ea21 en las dos.
Conclusión	Con la misma entrada y las mismas reglas se obtiene la misma tabla preparada.
Qué cambia entre ejecuciones	Solo la fecha y hora de cada registro de la bitácora.

Limitaciones

- Volumen, no riesgo. Los conteos son reportes recibidos por el C5. No se ajustaron por población, tráfico ni kilómetros de vialidad, así que las alcaldías más grandes pueden aparecer arriba por su tamaño.

- Pendientes. Se excluyeron 59 registros sin delegacion_inicio (4 de 2017, 36 de 2018 y 19 de 2019), menos del 0.01 % del total. Se guardan en incidentes_pendientes.csv.
- Casos marcados y conservados. 5,244 falsas alarmas (0.8 %), 49 registros con fecha de otro año y 13 con coordenadas fuera de rango siguen dentro de los datos válidos y entran en los conteos.
- Cobertura. Los datos van del 07/12/2016 al 30/11/2019. 2016 solo tiene 19 registros y 2019 llega hasta noviembre. Los promedios diarios usan el periodo completo, del 01/01/2017 al 30/11/2019.
- Hora del reporte. La franja horaria se obtiene de la hora de creación del reporte, no de la hora real del incidente.
- Sin causalidad. No se calcularon correlaciones, por lo que no se afirma ninguna relación de causa.
- Bitácora. bitacora.csv registra los 16 pasos del proceso, con sus conteos, reglas y

resultados, pero no el detalle de cada registro; ese detalle está en controles.csv e incidentes_pendientes.csv.
- Entorno. El notebook está escrito para Google Colab y lee los CSV desde Google Drive.

Siguientes pasos

1. Revisar con el profesorado qué hacer con las falsas alarmas y los casos con fecha o coordenadas fuera de rango.

2. Obtener datos de población o vialidad para comparar las alcaldías por tasa y no solo por volumen.
3. Cargar los datos preparados en PostgreSQL y definir su modelo, en la siguiente etapa del proyecto.

Cierre

El proceso convierte los tres archivos crudos en una tabla preparada de 680,687 incidentes, explica el destino de cada registro (680,746 = 0 + 680,687 + 59) y permite repetirse con el mismo resultado. Los primeros hallazgos señalan a Iztapalapa, los viernes y sábados y la franja de la noche como las mayores concentraciones de reportes.

8. Bitácora de equipo

Esta bitácora describe cómo se organizó el trabajo de esta entrega: qué se hizo, quién estuvo a cargo de cada tarea, dónde está la evidencia y en qué estado se encuentra.

Tabla 19. Bitácora de equipo

Tarea	Descripción	Responsable principal	Evidencia producida	Estado
Continuidad y ajuste por retroalimentación	Se retomaron la pregunta, la decisión, las fuentes y las variables, y se registraron los ajustes de la R4 y bitácora de equipo indicados por la docente.	Rosa Isela	Sección 1, Tablas 1 y 2	Completo
Configuración y bitácora automática	Se definieron rutas, carpetas de salida y la función anotar().	Rosa Isela	Notebook, sección 0	Completo

Extracción e integración	Se leyeron los 3 CSV, se verificaron sus columnas y se unieron con concat.	Rosa Isela	Notebook, secciones 1 y 2; Tablas 3 y 4	Completo
Transformación	Se aplicaron R1–R3 y se crearon hora, franja_horaria y las marcas.	Rosa Isela	Notebook, sección 3; Tablas 5 a 7	Completo
Validación y guardado	Se aplicó R4, se ejecutaron 9 controles y se exportaron preparados, pendientes y controles.	Rosa Isela	Notebook, secciones 4 y 5; data/processed/	Completo
Conciliación y resumen	Se comprobó 680,746 = 0 + 680,687 + 59 y se generó el resumen por alcaldía, día y franja.	Rosa Isela	Notebook, secciones 6 y 7; Tablas 8 a 10	Completo
Estadística descriptiva	Se calcularon e interpretaron 5 medidas (M1 a M5).	Sarai	Notebook, sección 8; Tablas 11 a 15	Completo
Bitácora automática en el informe	Se documentaron los campos de anotar() y los 16 pasos de bitacora.csv.	Sarai	Sección 6; Tablas 16 y 17; bitacora.csv	Completo
Reproducibilidad y limitaciones	Se repitió el ETL, se compararon las huellas y se redactaron limitaciones y siguientes pasos.	Sarai	Notebook, sección 9; sección 7, Tabla 18	Completo
Bitácora del equipo	Registro de tareas, responsables y evidencias del avance.	Sarai	Sección 8, Tabla 19	Completo

README y repositorio	Actualización de fuentes, rutas, dependencias y orden de ejecución; organización de carpetas.	Sarai	README.md y carpetas del repositorio	Pendiente
Exposición	Diapositivas de síntesis y demostración del ETL.	Sarai, Rosa Isela	presentacion/ (PDF)	Pendiente